

The linear least squares problems (Minimi quadrati lineari)

Elena Loli Piccolomini
elena.loli@unibo.it

Academic Year 2020/2021
Last updated: September 2020

1 Introduzione

Si consideri il seguente sistema

$$Ax = b \quad A \in \mathbb{R}^{m \times n} \quad b \in \mathbb{R}^m \quad x \in \mathbb{R}^n$$

se $m > n$ risulta essere sovradeterminato, cioè il numero di equazioni è strettamente superiore al numero di incognite, e in tal caso il sistema non ammette soluzioni.

Si definisce allora il ***problema ai minimi quadrati (LSQ)***, che consiste nel determinare il vettore $x \in \mathbb{R}^n$ che minimizzi il ***vettore dei residui*** $r = Ax - b$:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2 = \min_{x \in \mathbb{R}^n} \|r\|_2^2 \quad (1)$$

dove $r = (r_1, r_2, \dots, r_n) = (Ax_1 - b_1, \dots, Ax_n - b_n)$.

Proposition 1.1. Sia A una matrice $m \times n$, con $m > n$ e $rg(A) = k \leq n$. Allora il problema

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

ammette sempre almeno una soluzione.

Inoltre:

- Se $k = n$ il problema ha una ed una sola soluzione;
- Se $k < n$ il problema ha infinite soluzioni ;
(tali soluzioni formano un sottospazio di $\mathbb{R}^n$ di dimensione $n - k$)

2 Calcolo delle soluzioni

2.1 Caso $k = n$ Equazioni Normali

$$\begin{aligned} \|Ax - b\|_2^2 &= (Ax - b)^T (Ax - b) \\ &= (-b^T + x^T A^T)(Ax - b) \\ &= -b^T Ax + b^T b + x^T A^T Ax - x^T A^T b \\ &\quad (\text{sommando i termini simili } b^T Ax = x^T A^T b) \\ &= x^T A^T Ax - 2x^T Ab + b^T b \end{aligned}$$

Si pone:

$$f(x) = x^T A^T Ax - 2x^T Ab + b^T b \quad (2)$$

Per minimizzare la norma bisogna imporre che la derivata prima sia nulla, in questo caso non avendo una sola un'incognita bisogna usare il gradiente, che per una generica funzione è definito come segue:

$$f : \mathbb{R}^n \rightarrow \mathbb{R} \quad \nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

Nel caso di (2) si ha:

- $\nabla(x^T A^T Ax) = 2A^T Ax$
- $\nabla(2x^T Ab) = A^T b$
- $\nabla(b^T b) = 0$

Allora:

$$\nabla f(x) = 2A^T Ax - A^T b \quad (3)$$

Imponendo che il gradiente sia nullo si ottiene:

$$\boxed{A^T A x = A^T b} \quad \text{Sistema delle equazioni normali} \quad (4)$$

Se $A^T A$ è simmetrica e definita positiva allora A ha rango massimo: è possibile risolvere il sistema con un opportuno metodo adatto alla matrice $A^T A$. Ad esempio utilizzando la fattorizzazione di Cholesky, si ottiene una matrice L t.c. $A^T A = LL^T$ e si risolvono nell'ordine i due sistemi:

$$Ly = A^T b \quad L^T x = y$$

È possibile utilizzare anche altri metodi come il metodo dei Gradienti coniugati.

Il calcolo di $A^T A$ può rendere il problema eccessivamente mal condizionato poiché:

$$K(A^T A) = K(A)^2$$

2.2 Caso $k < n$ Decomposizione in valori singolari (SVD)

In questo caso vi sono infinite soluzioni, ma ne esiste una sola $\tilde{x}$ di norma minima tale che:

$$\tilde{x} \in \mathcal{N}(A)^\perp$$

Dove $\mathcal{N}(A)^\perp = \{y \in \mathbb{R}^n | A^T y = 0\}$ è lo spazio nullo.

Tale soluzione è ottenuta tramite SVD:

Theorem 2.1. *Sia $A \in \mathbb{R}^{m \times n}$, con $m \geq n$ e $rg(A) = k \leq n$. Allora esistono:*

- $U = [u_1, u_2, \dots, u_m] \in \mathbb{R}^{m \times m}$ ortogonale;
- $V = [v_1, v_2, \dots, v_n] \in \mathbb{R}^{n \times n}$ ortogonale;
- $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ con $\sigma_1 \geq \sigma_2 \cdots \geq \sigma_n \geq 0$ detti **valori singolari**;

tali che:

$$A = U \Sigma V^T \quad (5)$$

$$\begin{array}{c} n \\ \boxed{A} \\ m \end{array} = \begin{array}{c} m \\ \boxed{U} \\ m \end{array} \begin{array}{c} n \\ \boxed{\Sigma} \\ m \end{array} \begin{array}{c} n \\ \boxed{V^T} \\ n \end{array}$$

Theorem 2.2. Sia $A \in \mathbb{R}^{m \times n}$, con $rg(A) = k \leq n$ e sia $A = U\Sigma V^T$ la sua decomposizione in valori singolari, allora il vettore:

$$x^* = \sum_{i=1}^k \frac{u_i^T b}{\sigma_i} v_i \quad (6)$$

è la soluzione di minima norma del problema:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

in corrispondenza di tale soluzione si ottiene:

$$\|r\|_2^2 = \|Ax^* - b\|_2^2 = \sum_{i=k+1}^n (u_i^T b)^2 \quad (7)$$

Infatti moltiplicando per U^T a sinistra:

$$\begin{aligned} \|Ax - b\|_2^2 &= \|U^T Ax - U^T b\|_2^2 \\ &= \|U^T AV V^T x - U^T b\|_2^2 \end{aligned}$$

Posto $y = V^T x \in \mathbb{R}^n$ e $g = U^T b \in \mathbb{R}^m$

Se $A = U\Sigma V^T \Rightarrow U^T AV = \Sigma$

Allora:

$$\begin{aligned} \|Ax - b\|_2^2 &= \|\Sigma y - g\|_2^2 \\ &= \sum_{i=1}^k (\sigma_i y_i - g_i)^2 + \sum_{i=k+1}^n g_i^2 \end{aligned}$$

Per minimizzare tale quantità è sufficiente scegliere:

$$y_i = \frac{g_i}{\sigma_i} = \frac{U^T b}{\sigma_i} \quad i = 1, \dots, k$$

Poichè $x^* = Vy$ risulta:

$$x^* = \sum_{i=1}^k \frac{u_i^T b}{\sigma_i} v_i$$

Allora in corrispondenza di tale soluzione, la norma del residuo è:

$$\|r\|_2^2 = \sum_{i=k+1}^n (g_i)^2 = \sum_{i=k+1}^n (u_i^T b)^2$$

3 Definizione di pseudoinversa

Sia $A \in \mathbb{R}^{m \times n}$, con $rg(A) = k \leq \min(m, n)$ e $A = U\Sigma V^T$ la sua decomposizione in valori singolari. Si definisce **pseudoinversa** la matrice:

$$A^+ = V\Sigma^+U^T \quad \text{dove} \quad (\Sigma^+)_{ij} = \begin{cases} \frac{1}{\sigma_i} & \text{se } i = j \text{ e } i \leq k \\ 0 & \text{altrimenti} \end{cases}$$

Proprietà

1. $AA^+A = A$
2. $A^+AA^+ = A^+$
3. $(AA^+)^T = AA^+$
4. $(A^+A)^T = A^+A$

La pseudoinversa di una matrice rettangolare A permette di scrivere la soluzione del problema dei minimi quadrati (1) in modo simile alla soluzione $x = A^{-1}b$ di un sistema lineare quadrato, cioè (6) è equivalente a:

$$x^* = V\Sigma^+U^Tb \quad \implies \quad \boxed{x^* = A^+b}$$

Si osservi però che la pseudoinversa è uno strumento molto utile per analizzare teoricamente il problema LSQ e le proprietà delle sue soluzioni, ma NON è uno strumento adeguato per calcolarle poiché computazionalmente costoso.

Si può inoltre definire il numero di condizionamento di $A \in \mathbb{R}^{m \times n}$ in termini della pseudoinversa:

$$K(A) = \|A\| \|A^+\|$$

e il numero di condizionamento spettrale (o in norma-2):

$$K(A)_2 = \|A\|_2 \|A^+\|_2 = \frac{\sigma_1}{\sigma_n}$$

4 Condizionamento del problema dei minimi quadrati

Il numero di condizionamento della matrice del LSQ permette di stimare l'errore ottenuto nella soluzione quando viene utilizzato l'approccio della SVD.

Theorem 4.1. *Sia $A \in \mathbb{R}^{m \times n}$ con $m > n$ una matrice di rango $rg(A) = k \leq n$ e sia $\Delta A \in \mathbb{R}^{m \times n}$ una sua perturbazione. Sia $b \in \mathbb{R}^m$ il termine noto e $\delta b \in \mathbb{R}^m$ una sua perturbazione.*

Tali che:

- $rg(A + \Delta A) = k$
- $\|A^+\| \|\Delta A\| < 1$

se $x + \delta x$ è la soluzione del problema dei minimi quadrati perturbato:

$$\min_{y \in \mathbb{R}^m} \|(A + \Delta A)y - (b + \delta b)\|_2^2$$

allora risulta:

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \frac{K_2(A)}{1 - \epsilon_A K_2(A)} [c_1 \epsilon_A + c_2 \epsilon_b]$$

dove:

- $\epsilon_A = \frac{\|\Delta A\|}{\|A\|} \quad \epsilon_B = \frac{\|\delta b\|}{\|b\|}$
- c_1 è una funzione di $K_2(A)$, r , $\|A\|_2$, $\|r\|_2$
- c_2 è una funzione di $\|b\|$, $\|A\|_2$, $\|x\|_2$

I valori singolari hanno le seguenti proprietà:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k > \sigma_{k+1} = \sigma_{k+2} = \dots = \sigma_n = 0$$

dove $k = \text{rank}(A)$. La matrice Σ è unica mentre le matrici U and V non lo sono.

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n \\ 0 & \dots & 0 \\ \vdots & & \vdots \\ 0 & \dots & 0 \end{bmatrix}.$$

Results

– Poichè:

$$Av_i = \lambda_i v_i$$

v_i sono chiamati *vettori singolari destri* and u_i sono chiamati *vettori singolari sinistri*.

– Abbiamo la seguente relazione fra i valori singolari di A e gli autovalori di $A^T A$

$$A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T$$

$$\mathbf{A}^T \mathbf{A} = \mathbf{V} \mathbf{\Sigma}^T \mathbf{\Sigma} \mathbf{V}^T = \mathbf{V} \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n^2 \end{bmatrix} \mathbf{V}^T.$$

Quindi

e

$$\sigma_i = \sqrt{\lambda_i(A^T A)}, \quad i = \dots, n$$

In particolare

$$\sigma_1 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\rho(A^T A)} = \|A\|_2$$

$$\sigma_n = \sqrt{\lambda_{\min}(A^T A)} \implies \|A^{-1}\| = \frac{1}{\sigma_n}$$

Thus,

$$K(A) = \frac{\sigma_1}{\sigma_2}$$

- I valori singolari sinistri di A are the eigenvectors of $A^T A$
- I vettori singolari destri di A sono gli autovalori di AA^T

4.1 Approssimazione di matrici usando la SVD

Data la SVD di una matrice $A \in \mathbb{R}^{m \times n}$,

$$A = U\Sigma V^T$$

, possiamo usarla per rappresentare (o approssimare) la matrice A come somma di matrici $A_i \in \mathbb{R}^{m \times n}$ con $\text{rank}(A_i) = 1$ tali che:

$$A_i = u_i v_i^T$$

La matrice A of $\text{rank}(A) = k$ può essere scritta come

$$A = \sum_{i=1}^k \sigma_i A_i = \sum_{i=1}^k \sigma_i u_i v_i^T$$

Per ottenere una approssimazione di rango p A_p ($p < k$) di A possiamo trancare la somma all'indice $i = p$. L'errore introdotto con questa approssimazione può essere calcolato come

$$\|A - A_p\|_2 = \left\| \sum_{i=p+1}^k \sigma_i A_i \right\|_2 = \sigma_{p+1}$$

Questo significa che se σ_{p+1} è piccolo si ha una buona approssimazione della matrice originale A .

Theorem 4.2. Data $A \in \mathbb{R}^{m \times n}$, $\text{rank}(A) = k$, let $A = U\Sigma V^T$ sia la sua decomposizione in valori singolari. Sia $A_p = \sum_{i=1}^p \sigma_i u_i v_i^T$ la approssimazione di rango p di A . Allora


$$\forall B \in \mathbb{R}^{m \times n}, \text{rank}(B) = p, \|A - A_p\|_2 \leq \|A - B\|_2$$

Quindi possiamo dire che A_p è la migliore approssimazione di rango p di A .


Esempio. *Approssimazione di rango p di una matrice che rappresenta un'immagine.*




(a) Original image A .




(b) A_1 , $\sigma_1 \approx 228,052$.




(c) A_2 , $\sigma_2 \approx 40,647$.



(d) A_3 , $\sigma_3 \approx 26,125$.




(e) A_4 , $\sigma_4 \approx 20,232$.



(f) A_5 , $\sigma_5 \approx 15,436$.




(a) Original image A .




(b) Rank-1 approximation $\hat{A}(1)$.




(c) Rank-2 approximation $\hat{A}(2)$.



(d) Rank-3 approximation $\hat{A}(3)$.



(e) Rank-4 approximation $\hat{A}(4)$.



(f) Rank-5 approximation $\hat{A}(5)$.

La matrice associata all'immagine originale ha dimensione $m \times n = 1432 \times 1910$, quindi richiede 2735120 dati. Se consideriamo la approssimazione di rango p , richiede $(m+n+1) \times p$ dati. Per esempio, la approssimazione di rango 5 richiede $5 \times (1432 + 1910 + 1) = 16715$ dati, che corrispondono a circa 0.6% del numero di dati originali. Quindi possiamo interpretare la approssimazione

di rango p di una matrice come una compressione. Questa approssimazione si trova in diverse applicazioni per esempio di machine learning, di image processing, filtraggio di segnali e nella analisi delle componenti principali (PCA).