

SVD e Minimi Quadrati Lineari

Calcolo Numerico - A.A. 2024-25

October 11, 2025

sommario

- 1 Vettori e matrici ortogonali
- 2 Decomposizione in Valori Singolari
- 3 Il problema lineare dei minimi quadrati

Vettori ortogonali e ortonormali

- I vettori $v_1, v_2, \dots, v_m$ vettori di R^n Si dicono **ortogonali** se:

$$v_i^T v_j = 0, \quad \text{se } i \neq j$$

I vettori $x = (1, 1)$ e $y = (-1, 1) \in R^2$ sono ortogonali.

$$x^T y = \begin{pmatrix} 1 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = -1 + 1 = 0$$

- I vettori $v_1, v_2, \dots, v_m$ si dicono **ortonormali** se sono ortogonali e di lunghezza unitaria ($v_i^T v_i = \|v_i\| = 1$).

I vettori $x = \frac{1}{\sqrt{2}}(1, 1)$ e $y = \frac{1}{\sqrt{2}}(-1, 1)$ sono ortonormali.

$$v, w \in \mathbb{R}^3$$

$$v = \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix} \quad w = \begin{pmatrix} +1 \\ 1 \\ 3 \end{pmatrix}$$

$$v^T \cdot w = +1 + 2 - 3 = 0$$

v e w sono ortogonali

$$\|v\|_2 = \sqrt{1^2 + 2^2 + (-1)^2} = \sqrt{6}$$

$$\|w\|_2 = \sqrt{1^2 + 1^2 + 3^2} = \sqrt{11}$$

v e w **NON** sono ortonormali

$$\bar{v} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}$$

$$\bar{w} = \frac{1}{\sqrt{11}} \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}$$

sono
ortonormali

Matrici ortogonali

Una matrice W di dimensione $n \times n$ si dice **ortogonale** se le sue colonne sono vettori ortonormali.

La matrice

$$W = \begin{pmatrix} \frac{1}{\sqrt{3}} & 0 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & 1 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & 0 & 0 \end{pmatrix}$$

$w_1 \quad w_2 \quad w_3$

w_i sono ortonormali.

$w_i^T w_j = \begin{cases} 0 & \text{se } i \neq j \\ 1 & \text{se } i = j \end{cases}$

Proprietà' di una matrice ortogonale:

- 1 $W^T = W^{-1}$
- 2 $\forall x \in \mathbb{R}^n, \|x\|_2 = \|Wx\|_2$ quindi W è una **isometria**, cioè mantiene le distanze.

Precedenza:

A $n \times n$ autovalori $\lambda_i \in \mathbb{C}$, $i=1 \dots n$
autovettori $x_i \in \mathbb{C}^n$

$$A x_i = \lambda_i x_i \quad i=1 \dots n$$

Teorema diagonalizzabile

Se gli autovettori di A sono l.i.,
allora

$$A = P \cdot D \cdot P^{-1}$$
$$D = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} \quad P = \begin{pmatrix} x_1 & \dots & x_n \end{pmatrix}$$

Decomposizione in Valori Singolari (SVD)

- La Decomposizione in Valori Singolari (SVD) è uno strumento utilissimo, sia dal punto di vista teorico che computazionale.
- Data una matrice $A \in \mathbb{R}^{m \times n}$, la SVD costruisce basi ortogonali di $\mathbb{R}^m$ e $\mathbb{R}^n$ che permettono di rappresentare A attraverso una matrice diagonale.

SVD

$m > n$ ~~ma~~ si può fare la SVD anche nel
caso $m \leq n$.

Teorema. Sia A una matrice reale $m \times n$ di rango k , $k \leq n \leq m$. Allora esistono:

- una matrice ortogonale U $m \times m$
- una matrice ortogonale V $n \times n$
- una matrice diagonale Σ $m \times n$

tali che:

$$A = U \Sigma V^T, \quad \Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & \dots & \dots & \\ & & \sigma_n & \\ & & & 0 \end{pmatrix}$$

Diagram illustrating the dimensions and structure of the matrices in the SVD decomposition:

- A is an $m \times n$ matrix (indicated by pink labels $m \times n$ and a pink box around the equation).
- U is an $m \times m$ orthogonal matrix (indicated by a pink label $m \times m$ and a blue arc connecting it to the first m rows of Σ).
- V is an $n \times n$ orthogonal matrix (indicated by a pink label $n \times n$ and a blue arc connecting it to the first n columns of Σ).
- Σ is an $m \times n$ diagonal matrix (indicated by a pink label $m \times n$ and a blue arc connecting it to the first n columns of Σ).
- The matrix Σ is shown as a large matrix with m rows and n columns. The first n columns contain the singular values $\sigma_1, \sigma_2, \dots, \sigma_n$ on the diagonal, and the remaining $m-n$ columns are zero (indicated by blue circles).

SVD (cont.)

$m > n$

$$\begin{matrix} n \\ m \end{matrix} \boxed{A} = \begin{matrix} m \\ m \end{matrix} \boxed{U} \begin{matrix} m \\ n \end{matrix} \boxed{\Sigma} \begin{matrix} n \\ n \end{matrix} \boxed{V^T} \quad (1)$$

$m \leq n$

$$\begin{matrix} m \\ m \end{matrix} \boxed{A} = \begin{matrix} m \\ m \end{matrix} \boxed{U} \begin{matrix} m \\ m \end{matrix} \boxed{\Sigma} \begin{matrix} m \\ m \end{matrix} \boxed{V^T} \quad (2)$$

SVD (cont.)

Gli elementi $\sigma_1 \geq \sigma_2 \geq \dots \sigma_n \geq 0$ sono i **valori singolari** di A . Il rango k è uguale al numero di valori singolari positivi, i.e. $k = \text{rango}(A)$ sse $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k > 0$ e $\sigma_{k+1} = \dots = \sigma_n = 0$.

Le colonne di $U = (\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_m)$ e di $V = (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n)$ sono, rispettivamente, i **vettori singolari sinistri e destri di A** associati ai valori singolari σ_i e formano una base ortonormale di R^m e R^n , rispettivamente, poichè vale la relazione:

$$A \mathbf{u}_i = \sigma_i \mathbf{v}_i \quad \star$$

$$A = U \Sigma V^T \quad \text{mult. } U^T \Rightarrow$$

$$U^T A = \underbrace{U^T U} \Sigma V^T \Rightarrow U^T A = \Sigma V^T$$

SVD: decomposizione diadica

Teorema. *Se la matrice reale $A \in \mathbb{R}^{m \times n}$ ($m \geq n$) ha rango k e decomposizione in valori singolari $A = U\Sigma V^T$ (come nel teorema precedente), allora A può essere scritta nella forma diadica come somma di matrici di rango 1 (diadi):*

$$A = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

SVD: risultati

$$(A \cdot B)^T = B^T \cdot A^T \Rightarrow (U \Sigma V^T)^T = (V^T)^T \Sigma^T U^T = V \Sigma^T U^T$$

Abbiamo la seguente relazione fra i valori singolari di A e gli autovalori di $A^T A$:

$$\rightarrow A^T A = \underbrace{(U \Sigma V^T)^T}_A \underbrace{(U \Sigma V^T)}_A = V \Sigma^T \underbrace{U^T U}_I \Sigma V^T$$

$U^T U = I$

$$A^T A = \underbrace{V \Sigma^T \Sigma V^T}_{n \times n} = V \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n^2 \end{bmatrix} V^T$$

$\Sigma^T \Sigma$ and Σ^{-1}

Hence

$$\sigma_i = \sqrt{\lambda_i(A^T A)}, \quad i = \dots, n$$

$$A^T A = V \begin{pmatrix} \sigma_1^2 & & & \\ & \sigma_2^2 & & \\ & & \ddots & \\ & & & \sigma_m^2 \end{pmatrix} V^{-1} \Rightarrow$$

decomposizione agli autovalori di $A^T A$

$$\Rightarrow \sigma_1^2 = \lambda_1$$

$$\sigma_2^2 = \lambda_2$$

$$\vdots$$

$$\sigma_m^2 = \lambda_m$$

SVD: risultati

$$\|A\|_2 = \sqrt{\rho(A^T A)} = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_1(A^T A)}$$

raggio spettrale

In particolare:

- $\rightarrow \sigma_1 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\rho(A^T A)} = \|A\|_2$

- $\rightarrow \sigma_k = \sqrt{\lambda_{\min}(A^T A)} \Rightarrow \|A^{-1}\| = \frac{1}{\sigma_k}$

- $$K(A) = \frac{\sigma_1}{\sigma_k}$$

- norma di Frobenius:

$$\|A\|_F = (\sigma_1^2 + \sigma_2^2 + \dots + \sigma_k^2)^{1/2}$$

dalla relazione fra autovalori di $A^T A$ e valori singolari di A :

$$\sigma_1 = \sqrt{\lambda_1(A^T A)} \quad (m = \text{rg}(A))$$

$$\sigma_m = \sqrt{\lambda_m(A^T A)}$$

$$\sigma_1 = \|A\|_2 \quad \text{x definizione}$$

$$\sigma_m \stackrel{?}{=} \|A^{-1}\|_2.$$

$$\|A^{-1}\|_2 = \sqrt{\lambda_{\max}(A^{-1})^T \cdot A^{-1}}$$

Ricorda:

gli autovalori μ_i di A^{-1} sono l'inverso degli autovalori di A (λ_i)

$$\mu_1 = \frac{1}{\lambda_1}, \mu_2 = \frac{1}{\lambda_2} \dots \mu_m = \frac{1}{\lambda_m}$$

i valori singolari di A^{-1} sono
l'inverso dei val. singolari di A

$$\frac{1}{\sigma_1}, \frac{1}{\sigma_2}, \dots, \frac{1}{\sigma_n}$$

quindi poiché

$$\|A^{-1}\| = \sigma_{\max}(A^{-1}) = \frac{1}{\sigma_{\min}(A)}$$

$$\kappa(A) = \|A\|_2 \|A^{-1}\|_2 = \sigma_1 \cdot \frac{1}{\sigma_n} = \frac{\sigma_1}{\sigma_n}$$

$\Rightarrow$ i valori singolari danno informazioni:

1) rango di A

2) $\|A\|_2$

3) $\kappa_2(A)$ numero di conditione

Il problema lineare dei minimi quadrati

$$m \geq n$$

Vogliamo ora risolvere il sistema

$$\rightarrow \underline{Ax = b}, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^M, \quad x \in \mathbb{R}^n$$

Il sistema in generale **non ha soluzioni**.

Cerchiamo allora di rendere più piccolo possibile il vettore **residuo**:

$$r = Ax - b$$

Il problema lineare dei minimi quadrati (Linear Least Squares LSQ) è formulato come:

$$\min_x \|b - Ax\|_2^2$$

Il problema lineare dei minimi quadrati

Teorema. *Condizione necessaria e sufficiente affinché $\mathbf{x}^*$ sia soluzione del problema LSQ è che soddisfi le equazioni normali:*

$$A^T(b - A\mathbf{x}) = 0.$$

Dimostrazione

Detta $\rho(\mathbf{x}) = \|\mathbf{b} - A\mathbf{x}\|_2^2$, si ha che:

$$\nabla \rho(\mathbf{x}) = -2A^T(\mathbf{b} - A\mathbf{x})$$

Imponendo $\nabla \rho(\mathbf{x}) = 0$ si ha la tesi. □

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

$$A \text{ } m \times n \quad m \geq n \\ x \in \mathbb{R}^n \quad b \in \mathbb{R}^m$$

1) Quando c'è soluzione (unica)?

Il problema dei minimi è
sempre soluzione.

($\|Ax - b\|_2^2$ è una funzione convessa)

(A) $\text{rg}(A) = n$ (massimo)

(B) $\text{rg}(A) = k < n$ (non massimo)

(A) la soluzione è unica

(B) infinite soluzioni

2) Come calcolare la soluzione?

a) metodo dei gradienti
(calcolo 1 punto di minimo)

b) tecniche di algebra lineare

b1) $\text{rg}(A) = m$

risolvendo un sistema lineare

sistema delle equazioni normali

$$A^T A x = A^T b$$

(deriva dalle condizioni del 1°

ordine : $\nabla f(x) = 0$

$$\nabla \left(\|Ax - b\|_2^2 \right) = \underline{A^T A x - A^T b = 0}$$

$A^T A \rightarrow$ matrice quadrata
 $n \times n$

simmetrica, definita positiva
 $\Rightarrow$ non singolare

Il sistema ha una e una sola
soluzione (metodo di Cramer)
che calcolando si fattorizza
44.

Il problema lineare dei minimi quadrati

La matrice delle equazioni normali $A^T A$ (detta anche Gramiano) è quadrata, simmetrica e:

- se $r = n$ (cioè A ha rango massimo) allora è anche definita positiva e quindi il problema LSQ ha una **UNICA** soluzione.
- se $r < n$ (cioè A NON ha rango massimo) allora $A^T A$ è definita nonnegativa. In questo caso, le soluzioni del problema LSQ generano un sottospazio di R^n di dimensione $n - r$.

Quindi se $r < n$ la soluzione non è unica. Si può però rendere unica imponendo ulteriori condizioni come per esempio che la soluzione abbia minima norma in l_2 .

Calcolo delle soluzioni di un problema LSQ

Caso di rango massimo $=n$ *come si arriva alle equazioni normali?*

$$\begin{aligned}
 \|Ax - b\|_2^2 &= (Ax - b)^T (Ax - b) \\
 &= (-b^T + x^T A^T)(Ax - b) \\
 &= -b^T Ax + b^T b + x^T A^T Ax - x^T A^T b \\
 &\text{(sommando i termini simili } b^T Ax = x^T A^T b) \\
 &= x^T A^T Ax - 2x^T Ab + b^T b
 \end{aligned}$$

Si pone:

$$f(x) = x^T A^T Ax - 2x^T Ab + b^T b \quad (2)$$

Calcolo delle soluzioni di un problema LSQ

Per minimizzare la norma bisogna imporre che la derivata prima sia nulla, in questo caso non avendo una sola un'incognita bisogna usare il gradiente, che per una generica funzione è definito come segue:

$$f : \mathbb{R}^n \rightarrow \mathbb{R} \quad \nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

Nel caso di (2) si ha:

- $\nabla(x^T A^T A x) = 2A^T A x$
- $\nabla(2x^T A b) = A^T b$
- $\nabla(b^T b) = 0$

Allora:

$$\nabla f(x) = 2A^T A x - A^T b \quad (3)$$

quindi la soluzione unica del problema è la soluzione del sistema lineare:

$$A^T A x = A^T b$$



Risoluzione di un problema LSQ con SVD

least-squares (LSQ)

Teorema. La soluzione $\hat{\mathbf{x}}^*$ di norma minima del problema LSQ di rango r (che coincide con la soluzione del problema LSQ di rango massimo $r = n$) è data da:

$$\hat{\mathbf{x}}^* = A^+ \mathbf{b} = V \Sigma^+ U^T \mathbf{b} = \sum_{i=1}^r \frac{\mathbf{u}_i^T \mathbf{b}}{\sigma_i} \mathbf{v}_i$$

$\mathbb{R}^m \Rightarrow$ (pointing to $\hat{\mathbf{x}}^*$)
 $\mathbf{u}_i \in \mathbb{R}^n$
 $\mathbf{v}_i \in \mathbb{R}^m$

e le corrispondenti norme della soluzione e del residuo sono:

$$\|\hat{\mathbf{x}}^*\|_2^2 = \sum_{i=1}^r \left(\frac{\mathbf{u}_i^T \mathbf{b}}{\sigma_i} \right)^2 \quad \|\mathbf{r}^*\|_2^2 = \sum_{i=r+1}^n (\mathbf{u}_i^T \mathbf{b})^2$$

Risoluzione di un problema LSQ con SVD

Ortogonale, $\|U\|_2 = \|x\|_2$

Infatti moltiplicando per U^T a sinistra: $U^T(Ax - b) = U^T Ax - U^T b$

$$\begin{aligned} \rightarrow \|Ax - b\|_2^2 &= \|U^T Ax - U^T b\|_2^2 \\ &= \|U^T A V V^T x - U^T b\|_2^2 \end{aligned}$$

poiché V ortogonale

Posto $y = V^T x \in \mathbb{R}^n$ e $g = U^T b \in \mathbb{R}^m$

Se $A = U \Sigma V^T \Rightarrow U^T A V = \Sigma$

Allora:

da equare

$$\begin{aligned} \rightarrow \|Ax - b\|_2^2 &= \|\Sigma y - g\|_2^2 = \sum_{i=1}^m (\sigma_i y_i - g_i)^2 \\ &= \sum_{i=1}^k (\sigma_i y_i - g_i)^2 + \sum_{i=k+1}^m g_i^2 \end{aligned}$$

Per minimizzare tale quantità è sufficiente scegliere:

$$y_i = \frac{g_i}{\sigma_i} = \frac{U^T b}{\sigma_i} \quad i = 1, \dots, k$$

$$\min_x \|Ax - b\|_2^2 =$$

$$\underline{g = U^T b}, y = V^T x$$

$$= \min_x \sum_{i=1}^n (\sigma_i y_i - g_i)^2 + \sum_{i=n+1}^m g_i^2 \Leftrightarrow$$

$$\min_x \sum_{i=1}^n (\sigma_i y_i - g_i)^2 \Leftrightarrow$$

toujours ≥ 0

$$\sigma_i y_i - g_i = 0 \quad \forall i = 1..n$$

$$y_i = \frac{g_i}{\sigma_i} = \frac{U^T b_i}{\sigma_i}$$

soit lui-même g_i

Risoluzione di un problema LSQ con SVD

$$y = V^T x \Rightarrow V y = \underbrace{V V^T}_{I} x = V y = x$$

Poichè $x^* = V y$ risulta:



$$x^* = \sum_{i=1}^k \frac{u_i^T b}{\sigma_i} v_i$$

*soluzioni del
problema LSQ di
minimo errore*

Allora in corrispondenza di tale soluzione, la norma del residuo è:

$$\|r\|_2^2 = \sum_{i=k+1}^n (g_i)^2 = \sum_{i=k+1}^n (u_i^T b)^2$$

Definizione di pseudoinversa

Sia $A \in \mathbb{R}^{m \times n}$, con $\text{rg}(A) = k \leq \min(m, n)$ e $A = U\Sigma V^T$ la sua decomposizione in valori singolari. Si definisce **pseudoinversa** la matrice:

$$A^+ = V\Sigma^+U^T$$

dove $(\Sigma^+)_{ij} = \begin{cases} \frac{1}{\sigma_i} & \text{se } i = j \text{ e } i \leq k \\ 0 & \text{altrimenti} \end{cases}$

$$\begin{pmatrix} \frac{1}{\sigma_1} & & & & \\ & \frac{1}{\sigma_2} & & & \\ & & \ddots & & \\ & & & \frac{1}{\sigma_k} & \\ & & & & 0 \end{pmatrix}$$

Proprietà

1. $AA^+A = A$
2. $A^+AA^+ = A^+$
3. $(AA^+)^T = AA^+$
4. $(A^+A)^T = A^+A$

se $m=n$ e $\text{rg}(A) = m=n$
 $\Rightarrow A^+ = A^{-1}$

La pseudoinversa di una matrice rettangolare A permette di scrivere la soluzione del problema dei minimi quadrati (1) in modo simile alla soluzione $x = A^{-1}b$ di un sistema lineare quadrato, cioè (6) è equivalente a:

$$x^* = V\Sigma^+U^Tb \quad \Rightarrow$$

$$x^* = A^+b$$

Condizionamento di un problema LSQ

Definizione. Il numero di condizione in norma 2 (o numero di condizione spettrale) di una matrice $m \times n$ con valori singolari $\sigma_1 \geq \sigma_2 \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_n = 0$ è definito da:

$$\text{cond}(A) = \frac{\sigma_1}{\sigma_r}$$

Risultato. Se $\mathbf{x}^*$ è la soluzione del problema LSQ, si ha:

$$\frac{\|\Delta \mathbf{x}\|_2}{\|\mathbf{x}^*\|_2} \leq \text{cond}(A)^2 \frac{\|\Delta \mathbf{b}\|_2}{\|\mathbf{b}\|_2}$$

Complessità computazionale e numero di condizione

1 Caso rango massimo:

- Equazioni normali con Gauss: c.c. $mn^2 + 1/3n^3$, ~~cond. $K(A)^3$~~
- ~~Equazioni normali Cholesky ($A = LL^T$): c.c. $2mn^2 - 2/3n^3$, cond. $K(L)^2$~~

2 Caso rango non massimo:

- SVD c.c. $mn^2 \Rightarrow$ se $m \approx n$, c.c. m^3