


Metodi di discesa

Calcolo Numerico CdS Informatica

Generalità

- Gli algoritmi di ottimizzazione che consideriamo garantiscono, in generale, la determinazione di punti che soddisfano condizioni necessarie di ottimo.
- Tutti i metodi considerati consentono di determinare punti stazionari di f .
- Nel caso non convesso, la determinazione di punti stazionari non fornisce una soluzione globale e non è neanche possibile, in generale, garantire che sia raggiunto un punto di minimo locale.



Metodi di discesa

- Si consideri il problema della minimizzazione non vincolata di una funzione $f : \mathbb{R}^n \rightarrow \mathbb{R}$ differenziabile con continuità (cioè le cui derivate parziali sono anche funzioni continue).
- I metodi di discesa sono metodi iterativi che, a partire da un iterato iniziale $x_0 \in \mathbb{R}^n$, generano una successione di vettori

$$\underline{x}_0, \underline{x}_1, \underline{x}_2, \dots \in \mathbb{R}^n \quad x_k \xrightarrow[k \rightarrow \infty]{} x^*$$

definiti dall'iterazione

$$\underline{x}_{k+1} = \underline{x}_k + \alpha_k \underline{p}_k \quad (1)$$

dove il vettore p_k è una **direzio**ne di ricerca e lo scalare α_k è un parametro positivo chiamato **lunghezza del passo** (step-length) che indica la distanza di cui ci si deve muovere lungo la direzione p_k .

- Il vettore p_k ed il parametro α_k sono scelti in modo da garantire la decrescita di $f(x)$ ad ogni iterazione:


$$f(x_{k+1}) < f(x_k), \quad k = 0, 1, \dots$$

Direzione di discesa

Definizione

Il vettore p è una direzione di discesa di f in x se esiste un $\bar{\alpha} > 0$ tale che

$$f(x + \alpha p) < f(x) \text{ per ogni } \alpha \in (0, \bar{\alpha}]$$



*differentiabile con derivate parziali
continue*

Proposizione Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continuamente differenziabile nell'intorno di un punto $x \in \mathbb{R}^n$ e sia $p \in \mathbb{R}^n$ un vettore non nullo. Allora se risulta

$$p^T \nabla f(x) < 0$$

(2)

la direzione p è una direzione di discesa per f in x .

Esempio 1

$$\underline{x} = (x_1, x_2) \quad f: \mathbb{R}^2 \rightarrow \mathbb{R}$$

$$f(\underline{x}) = x_1^3 + x_2^2 - 3x_1$$

d è direzione di discesa per f in $\bar{x}$?

- Consideriamo il punto $\bar{x} = (-1, 0)^T$ e la direzione $d = (-1, 0)^T$
- Vale $\nabla f(\underline{x}) = \begin{pmatrix} 3x_1^2 - 3 \\ 2x_2 \end{pmatrix}$ e $\nabla f(\bar{x}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ ←
- La direzione d è di discesa. Infatti risulta $\bar{x} + td = (-1 - t, 0)^T$ e la funzione vale

$$f(\bar{x} + td) = (-1 - t)^3 - 3(-1 - t) = \underline{-t^3 - 3t^2 + 2}$$

La condizione $-t^3 - 3t^2 + 2 < 2 = f(\bar{x})$ è verificata per ogni $t > 0$.

$$\rightarrow d^T \cdot \nabla f(\bar{x}) < 0 \Rightarrow (-1, 0)^T \cdot \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0$$

• se $p^T \cdot \nabla f(x) < 0 \Rightarrow$ direzione di
discesa

• se $p^T \cdot \nabla f(x) > 0 \Rightarrow$ direzione asc
di discesa

→ se $p^T \cdot \nabla f(x) = 0 \Rightarrow$ direzione può
essere o no di discesa

Esempio 2

$$\rightarrow f(x_1, x_2) = x_1^3 + x_2^2 - 3x_1$$

- Consideriamo il punto $\tilde{x} = (1, 0)^T$ e la direzione $d = (-1, 0)^T$
- Vale $\nabla f(x) = \begin{pmatrix} 3x_1^2 - 3 \\ 2x_2 \end{pmatrix}$ e $\nabla f(\tilde{x}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ $d^T \cdot \nabla f(\tilde{x}) = 0$
- La direzione d non è di discesa. Infatti risulta $\tilde{x} + td = (1 - t, 0)^T$ e la funzione vale

$$f(\tilde{x} + td) = (1 - t)^3 - 3(1 - t) = -t^3 + 3t^2 - 2$$

La condizione $-t^3 + 3t^2 - 2 < -2 = f(\bar{x})$ è verificata solo per ogni $t > 3$

Verificare se p è una direzione di discesa per f in $\bar{x}$.

Dati: $f, \bar{x}, p$

- 1) calcolare $\nabla f(\bar{x}) \in \mathbb{R}^n$
- 2) $p^T \cdot \nabla f(\bar{x}) \begin{cases} > 0 \rightarrow \text{non discesa} \\ < 0 \rightarrow \text{discesa} \\ = 0 \rightarrow \text{non so} \end{cases}$
- 3) ~~ALTERNATIVA~~ a 2) $\rightarrow$ verificare la definizione.

Interpretazione geometrica



Ricordando che il concetto di angolo tra due vettori $x \neq 0$ e $y \neq 0$ in $\mathbb{R}^n$ si può introdurre attraverso la definizione di coseno, ponendo

$$\cos \theta = \frac{x^T y}{\|x\| \|y\|}$$

si può dire che l'angolo tra p e $\nabla f(x)$ è

- *ottuso* se $p^T \nabla f(x) < 0$
- *acuto* se $p^T \nabla f(x) > 0$


I vettori p e $\nabla f(x)$ sono *ortogonali* se $p^T \nabla f(x) = 0$.

La retta $x = x_k + \alpha p_k$ deve formare un angolo ottuso con la direzione del gradiente (derivata direzionale negativa):

$$p^T \cdot \nabla f(\bar{x}) < 0$$

$\Downarrow$

angolo tra
 p^T e $\nabla f(x)$
 è ottuso.



- Se $p^T \nabla f(x) < 0$ la direzione p è una direzione di discesa per f in x ;
- se $p^T \nabla f(x) > 0$ la direzione p è una direzione di salita per f in x ;
- se $p^T \nabla f(x) = 0$ non è possibile stabilire, in assenza di altre informazioni, se p sia o meno una direzione di discesa.





Illustration of the isocost surfaces of the quadratic cost function $f: \mathbb{R}^2 \mapsto \mathbb{R}$ given by

$$f(x, y) = \frac{1}{2}(\alpha x^2 + \beta y^2) - x$$

for various values of α and β .

- La direzione dell'antigradiente $p = -\nabla f(x)$ è sempre una direzione di discesa
- Nel caso generale (f non convessa), la condizione di discesa enunciata è solo sufficiente, in quanto possono esistere direzioni di discesa tali che $\nabla f(x)^T p = 0$.



Scelta di p_k direzione di discesa:

$$p_k = -\nabla f(x_k)$$

$$p_k^T \cdot \nabla f(x_k) = - \underbrace{\nabla f(x_k)^T \nabla f(x_k)}_{> 0} < 0$$

Scelta della lunghezza del passo

- Esistono diverse tecniche per determinare la lunghezza del passo in modo tale da garantire la convergenza del metodo verso punti stazionari di f . Esse sono, in generale, chiamate tecniche di ricerca in linea (line search) o di *ricerca unidimensionale* perchè la ricerca di un nuovo iterato x_{k+1} è fatta lungo la linea $y(\alpha) = x_k + \alpha p_k$.
- Osserviamo innanzitutto che la scelta di α_k tale che

$$f(x_{k+1}) < f(x_k)$$

non garantisce la convergenza del metodo.

NON È VERO CHE

$\underline{x}_0, \underline{x}_1 \dots \underline{x}_k, \underline{x}_{k+1} \dots$ tale che

• $\Rightarrow f(\underline{x}_{k+1}) < f(\underline{x}_k)$

• $\Rightarrow \lim_{k \rightarrow \infty} \underline{x}_k = \underline{x}^*$ pts di minimo
locale

- Gli algoritmi di ricerca unidimensionale hanno per obiettivo la determinazione del passo α_k lungo la direzione assegnata p_k e costituiscono usualmente la parte più complessa di un codice di calcolo per l'ottimizzazione non vincolata.
- In termini molto generali, si può dire che la ricerca unidimensionale è finalizzata, essenzialmente, ad assicurare la convergenza globale dell'algoritmo, mentre la rapidità di convergenza dipende in prevalenza dalla direzione di ricerca.
- Tuttavia, un valore di α_k poco appropriato può distruggere le proprietà di rapidità di convergenza associate alla scelta di p_k .
- Una tecnica di ricerca unidimensionale dovrebbe quindi anche assicurare che, almeno in intorno della soluzione, venga il più possibile accettato il passo che garantisce idealmente una buona rapidità di convergenza.
- Realizzare un compromesso tra le esigenze di convergenza globale e quelle di rapidità di convergenza può risultare difficile.

Esempio

CONTROESEMPIO di un algoritmo
tale che $f(x_{k+1}) < f(x_k)$ ma
 $x_k \not\rightarrow x^*$

Si consideri il problema

$$\min f(x) = x^2$$

con iterato iniziale $x_0 = -3$. Ad ogni iterazione usiamo la direzione di ricerca $p_k = 1$ con lunghezza del passo $\alpha_k = 2^{-k}$. Dunque

$$x_{k+1} = x_k + 2^{-k}.$$

$\forall k = 0, 1, \dots$

La successione delle soluzioni approssimate è

$$\begin{array}{ccccccc} x_0 & x_1 & x_2 & x_3 & x_4 & & \\ -3, & -2, & -\frac{3}{2}, & -\frac{5}{4}, & -\frac{9}{8} & \dots & \leftarrow \end{array}$$

con $x_k = -(1 + 2^{1-k})$. Ogni direzione p_k è una direzione di discesa:

$$p_k^T \nabla f(x_k) = 1 \times 2x_k = -2(1 + 2^{1-k}) < 0.$$

Vale $f(x_{k+1}) < f(x_k)$ ma la successione non converge alla soluzione $x^* = 0$:

$$\lim_{k \rightarrow \infty} x_k = -1 \quad \text{e} \quad f'(-1) = -2 \neq 0.$$

-1 non è pts minimo.

Ricerca in linea

Il passo α_k viene determinato con riferimento alla funzione di una sola variabile reale $\phi : \mathbb{R} \rightarrow \mathbb{R}$ definita (per k fissato) da:

$$\phi(\alpha) = f(x_k + \alpha p_k)$$

che caratterizza l'andamento di f lungo la direzione di ricerca p_k

Ricerca in linea esatta

- La scelta ideale è scegliere α_k come il punto di minimo globale della funzione

$$\phi(\alpha) = f(x_k + \alpha p), \quad \alpha \geq 0 \quad (3)$$

- La scelta di α_k impone che p_k e $\nabla f(x_{k+1})$ siano ortogonali, ovvero:

$$0 = \left. \frac{d}{d\alpha} \phi(\alpha) \right|_{\alpha=\alpha_k} = (\nabla f(x_k + \alpha_k p_k))^T p_k = (\nabla f(x_{k+1}))^T p_k$$

- Nella pratica, tale condizione è implementata solo in alcuni casi particolari perchè molto costosa computazionalmente. Infatti, per determinare α_k che soddisfa la (3) è necessario risolvere il sistema di equazioni non lineari $d\phi/d\alpha = 0$.

Ricerca in linea inesatta *per calcolare α_k*

In termini molto generali, i metodi di ricerca inesatta unidimensionale per cui è possibile stabilire risultati di convergenza si basano sull'individuazione di un *intervallo di valori accettabili* per α_k , definiti in modo tale da assicurare

- una sufficiente riduzione di f rispetto al valore corrente $f(x_k)$;
- un sufficiente spostamento rispetto al punto corrente x_k .

Condizioni di Wolfe $\times$ decrescita di f "sufficiente" per avere la convergenza

Le condizioni di Wolfe sono date da x_{k+1}

sufficiente
decrescita

1)

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k$$

< 0

(4)

2)

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k$$

(5)

con $0 < c_1 < c_2 < 1$.

- La prima disuguaglianza (4), detta condizione di Armijo (Armijo condition o sufficient decrease condition), assicura una decrescita sufficiente di f nella direzione p .
- La seconda disuguaglianza (5), detta condizione della curvatura (curvature condition), impedisce che α_k divenga troppo piccolo.

Condizione di Armijo e Backtracking

- La condizione di Armijo da sola non è sufficiente a garantire che la lunghezza del passo non sia troppo piccola. Tuttavia, se la lunghezza del passo è scelta con una **tecnica di backtracking**, allora è sufficiente usare la condizione di Armijo per garantire la convergenza.
- Nell'algoritmo di backtracking, inizialmente si pone $\alpha = \bar{\alpha}$ (di solito $\bar{\alpha} = 1$). Quindi si riduce questo valore finchè non si sia trovato un valore α_k per cui sia soddisfatta la condizione di Armijo (4).

Algoritmo di backtracing

- Si esamina se l'attuale valore di α non soddisfa la condizione di Armijo, cioè, se

$$f(x_k + \alpha p_k) > f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k$$

- Se ciò avviene, si riduce α di un fattore $\rho < 1$, cioè si pone $\alpha = \rho \alpha$ e si esamina la condizione di Armijo con questo nuovo valore di α .
- Quando, finalmente, si trova un valore di α per cui la disuguaglianza di Armijo è soddisfatta, questo valore è il parametro α_k che si cercava.
- Nella pratica spesso si sceglie $\rho = \frac{1}{2}$ e quindi α_k è il primo numero della successione $\{1, \frac{1}{2}, \frac{1}{4}, \dots, \frac{1}{2^i}, \dots\}$ che verifica la condizione di Armijo.

Algoritmo di backtracing*Arresto*

Scegliere $\bar{\alpha} > 0$, $\rho, c_1 \in (0; 1)$; porre $\alpha = \bar{\alpha}$ e $j = 0$;
^{= 1}

while $f(x_k + \alpha p_k) > f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k$ *↖*

$\alpha = \rho \alpha$ e $j = j + 1$

end(repeat)

Porre $\alpha_k = \alpha$.

La condizione della curvatura di solito si implementa arrestando l'algoritmo di backtracking quando il valore di α (e quindi il passo) diventa troppo piccolo:

$$\alpha < \tau \quad \tau \simeq [10^{-8}, 10^{-10}]$$

Schema algoritmico

Un metodo con ricerca in linea è dunque un metodo iterativo che ha il seguente schema generale

Metodo con ricerca in linea

Dato x_0 , per $k = 0, 1, 2, \dots$

- i) determinare una direzione di discesa p_k ;
- ii) determinare una lunghezza del passo α_k ;
- iii) porre $x_{k+1} = x_k + \alpha_k p_k$ e $k + 1 = k$;

Criteri di arresto e fallimenti

- Negli algoritmi di ottimizzazione esistono diversi criteri per far terminare le iterazioni e che possono indicare il raggiungimento di una soluzione oppure il fallimento dell'algoritmo.
- Negli algoritmi di ottimizzazione non vincolata per criterio di arresto si intende il criterio che dovrebbe indicare il raggiungimento con successo di un punto stazionario con la tolleranza specificata dall'utente.
- Dal punto di vista teorico, il criterio di arresto di un algoritmo che genera la successione x_k dovrebbe essere la condizione

$$\|\nabla f(x_k)\| \leq \epsilon, \quad \epsilon > 0 \quad (6)$$

~~Altre condizioni di arresto:~~

- superamento di un massimo numero di iterazioni; *NON E' COND ARRESTO*
- fallimenti interni alle procedure usate dall'algoritmo per il calcolo di x_{k+1} (as esempio nella ricerca in linea); *NON CRITERIO ARRESTO*
- $\|x_{k+1} - x_k\| < \varepsilon_2$

Metodo del gradiente

- La direzione di ricerca è

$$p_k = -\nabla f(x_k) \quad \text{per ogni } k$$

La direzione dell'antigradiente $-\nabla f(x_k)$ è una direzione di discesa di f in x_k se $\nabla f(x_k) \neq 0$.

- La lunghezza del passo è determinata con una tecnica di ricerca in linea inesatta. (alg. backtracking)
- Esiste un teorema (teorema di Zoutendijk.) che assicura la convergenza globale ad un punto **di minimo locale**.

↓
 il pto iniziale x_0

Esercizio

Scrivere le prime due iterazioni del metodo del gradiente applicato alla funzione.

$$f(x_1, x_2) = x_1^2 - 3x_2^2$$

a partire dal punto iniziale $x_0 = (1, 1)$, con passo $\alpha = 0.1$ verificare la condizione di arresto assoluta sulla norma del gradiente con una tolleranza $\tau = 10^{-4}$.

$$f(x_1, x_2) = x_1^2 - 3x_2^2$$

$$\alpha = 0.1 \quad x_0 = (1, 1)$$

$$\underline{x}_1 = \underline{x}_0 - \alpha \nabla f(x_0)$$

$$\nabla f = \begin{pmatrix} 2x_1 \\ -6x_2 \end{pmatrix} \quad \nabla f(x_0) = \begin{pmatrix} 2 \\ -6 \end{pmatrix}$$

$$\underline{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \underset{\alpha}{0.1} \underset{\nabla f(x_0)}{\begin{pmatrix} 2 \\ -6 \end{pmatrix}} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 0.2 \\ -0.6 \end{pmatrix}$$

$$= \begin{pmatrix} 0.8 \\ 1.6 \end{pmatrix}$$

$$x_2 = x_1 - 0.1 \nabla f(x_1)$$

$\|\nabla f(x_2)\| < 10^{-4}?$

Algoritmo gradiente

Dati: $f, \nabla f, x_0, \varepsilon, \varepsilon_1$

$$k = 0$$

while condizione

- Applica alg. backtracking per calcolare

$$\alpha_k$$

- $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$

... condizione

- $k = k + 1$

Output: x_k, k

comp. algoritmo: $k \times$ complessità una iterazione

Il metodo di Newton puro (per l'ottimizzazione)

Una direzione alternativa a quella del metodo del gradiente è quella del metodo di Newton.

- Utilizza come direzione di ricerca la direzione di Newton

$$p_k = -H_f(x_k)^{-1} \nabla f(x_k)$$

dove $H_f(x_k)$ è la matrice Hessiana $\nabla^2 f(x_k)$.

- Questa direzione è ottenuta considerando lo sviluppo in serie di Taylor di $f(x)$ in un intorno di x_k

$$f(x_k + p) \approx f_k + p^T \nabla f_k + \frac{1}{2} p^T H_f p := m_k(p)$$

Supponendo che $H_f(x_k)$ sia definita positiva, la direzione di Newton è il vettore p che minimizza m_k .

- La lunghezza del passo è $\alpha_k = 1$ per ogni k .

hessiana di f
 $\nabla^2 f(x_k)$

- Dunque il metodo di Newton puro si scrive

$$\underline{x}_{k+1} = \underline{x}_k - \underline{H_f(x_k)^{-1} \nabla f(x_k)}$$

- Per trovare p_k **non** si inverte $H_f(x_k)$ ma si risolve il sistema $H_f(x_k)p = -\nabla f(x_k)$
- Come si comporta il metodo di Newton?
- La direzione di Newton è di discesa in x_k se l'Hessiana $H_f(x_k)$ è definita positiva.
- Poichè la matrice Hessiana $H_f(x_k)$ potrebbe non essere definita positiva, la direzione $p_k = -H_f(x_k)^{-1} \nabla f(x_k)$ potrebbe non essere di discesa.

Le proprietà di convergenza del metodo sono fortemente legate alla definita positività della matrice Hessiana!

Metodo di Newton

$$x_{k+1} = x_k - \underbrace{\left(\nabla^2 f(x_k) \right)^{-1}}_{P_k} \nabla f(x_k)$$

$$\alpha_k = 1$$

La direzione di ricerca è P_k ?

se $\nabla^2 f(x_k)$ è matrice (simmetrica)
definita positiva

Vantaggi e svantaggi del metodo di Newton puro?

Vantaggi:

- converge rapidamente quando si avvicina alla soluzione x^* . *ordine di convergenza è 2*

Svantaggi:

- può non convergere alla soluzione se l'iterato iniziale è "troppo distante" dalla soluzione;
- anche se converge, può avere un comportamento sbagliato se la funzione non è convessa;
- ha un elevato costo computazionale; *per il calcolo di H^{-1}*
- il "sistema di Newton" può essere mal condizionato.

Al fine di ottenere un metodo robusto ed efficiente è necessario modificare opportunamente il metodo di Newton puro! Esistono infatti varianti che però non esaminiamo in questo corso.

GRADIENTE

STOLA STICCO

$$\min_{x \in \mathbb{R}^n} F(x) = \underbrace{\sum_{i=1}^n f_i(x)}$$

$$\Rightarrow \nabla F(x) = \sum_{i=1}^n \nabla f_i(x)$$

$$\nabla (h_1 + h_2) = \nabla h_1 + \nabla h_2$$

gradiente lineare rispetto agli
argomenti

Nel gradiente stocastico (SGD)
approssimo $\nabla F(x)$ utilizzando solo
"ALCUNE" componenti $\nabla f_i(x)$

$$\nabla F(x) \simeq \sum_{i \in S_k} \nabla f_i(x)$$

$$S_k = \{i_1, i_2, \dots, i_k\} \subset [1, n]$$

Fissato k , scelgo $i_1, \dots, i_k$ in modo
casuale in $[1, n]$ senza ripetizioni.

EXAMPLE

$$n=8$$

$$k=2$$

$$[1, 2, \dots, 8]$$

$$\underline{x}_{j+1} = \underline{x}_j - \alpha_j \nabla F(x_j) \quad \text{it GD},$$

$$\underline{x}_{j+1} = \underline{x}_j - \alpha_j \sum_{i \in S_k} f_i(x_j) \quad \text{it SGD}$$

$$x_1 = x_0 - \alpha_0 \sum_{i \in S_2} f_i(x_0) =$$

$$x_0 - \alpha_0 \left(\nabla f_2(x_0) + \nabla f_5(x_0) \right)$$

$$x_2 = x_1 - \alpha_1 \sum_{i \in S_n} \nabla f_i(x_1) =$$

$$i \neq 2, 5$$

$$x_1 - \alpha_1 \left(\nabla f_{\textcircled{1}}(x_1) + \nabla f_{\textcircled{8}}(x_1) \right)$$

$$x_3 \dots$$

$$i \neq 2, 5, 1, 8$$

$$i = 3, 6$$

$$x_4 \dots$$

$$i = 4, 7$$

EPOCA → numero di iterazioni
necessarie ad utilizzare tutti

gli indici $1 \dots m$

per iterazioni $p = \frac{m}{k}$

MINI BATCH S_k

BATCH → $k=1$

α costante